

STEEL MEETS INTELLIGENCE

철강의 품질,
기술로 완성하다.

철강 표면 결함의 빠른 판별과 위치 표시

Severstal 데이터로 검토한 전처리와 모델 선택

김윤태 · 김현모 · 나영준 · 채영지

MINI PROJECT 01 / 2026.11

주제 선정 이유 산업 이미지 검수

학습한 모델을 실제 촬영 데이터의 제약과 연결해 보기 위해

01	**데이터의 형태**	일반 사진보다 가로로 긴 강판 이미지와 픽셀 마스크
02	**현장 판단**	놓친 결함과 정상 제품의 오경보를 따로 확인
03	**실행 제약**	이미지 축소로 처리 시간을 줄이고 손실을 측정
04	**조건 변화**	어두운 조명과 반사, 투입 오류를 합성해 취약점 점검

대회 데이터 기반 시연이며 실제 설비 카메라에서의 성능은 아직 확인하지 않았습니다.

정확도 한 숫자보다 결함 누락, 정상 오경보, 처리 시간, 위치 표시를 함께 판단했습니다.

분석 목표 결함 판별과 위치 표시

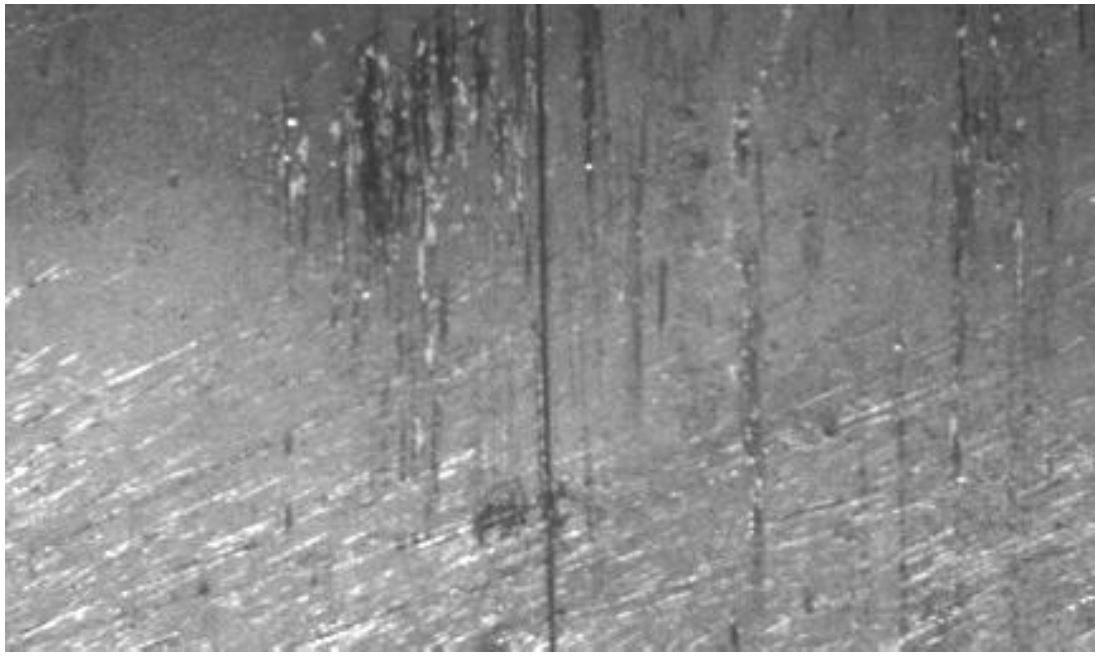
공개 Severstal 이미지를 활용한 생산 현장형 컴퓨터 비전 과제

현장에서 먼저 필요한 질문

01 이 강판에 결함이 있는가?

02 결함이 있다면 어디에 있는가?

03 조명이나 투입 상태가 바뀌면?



공개 산업 이미지 12,568장 | 결함 마스크 4종

결함 유무를 빠르게 알리고, 발견된 위치를 사진 위에 표시하는 문제를 선택했습니다.

발표 흐름

초기 기준선에서 최종 모델을 고르고 환경 변화까지 점검

1	**주제와 데이터**	강판 사진과 정답 마스크
2	**초기 기준선**	패치 전처리와 2단계 결함 판별
3	**각자의 전처리 실험**	채영지 → 김현모 → 김윤태
4	**최종 모델**	패치 분류 → 사진 한 장씩 판별 · 위치 표시
5	**환경 변화 고려**	조명·반사와 합성 공정 오류
6	**선택과 기대효과**	딥러닝 개선·검수 속도·현장 검증

패치 실험, 이미지 판별, 합성 환경 실험의 평가 단위를 구분해 해석합니다.

분석 데이터

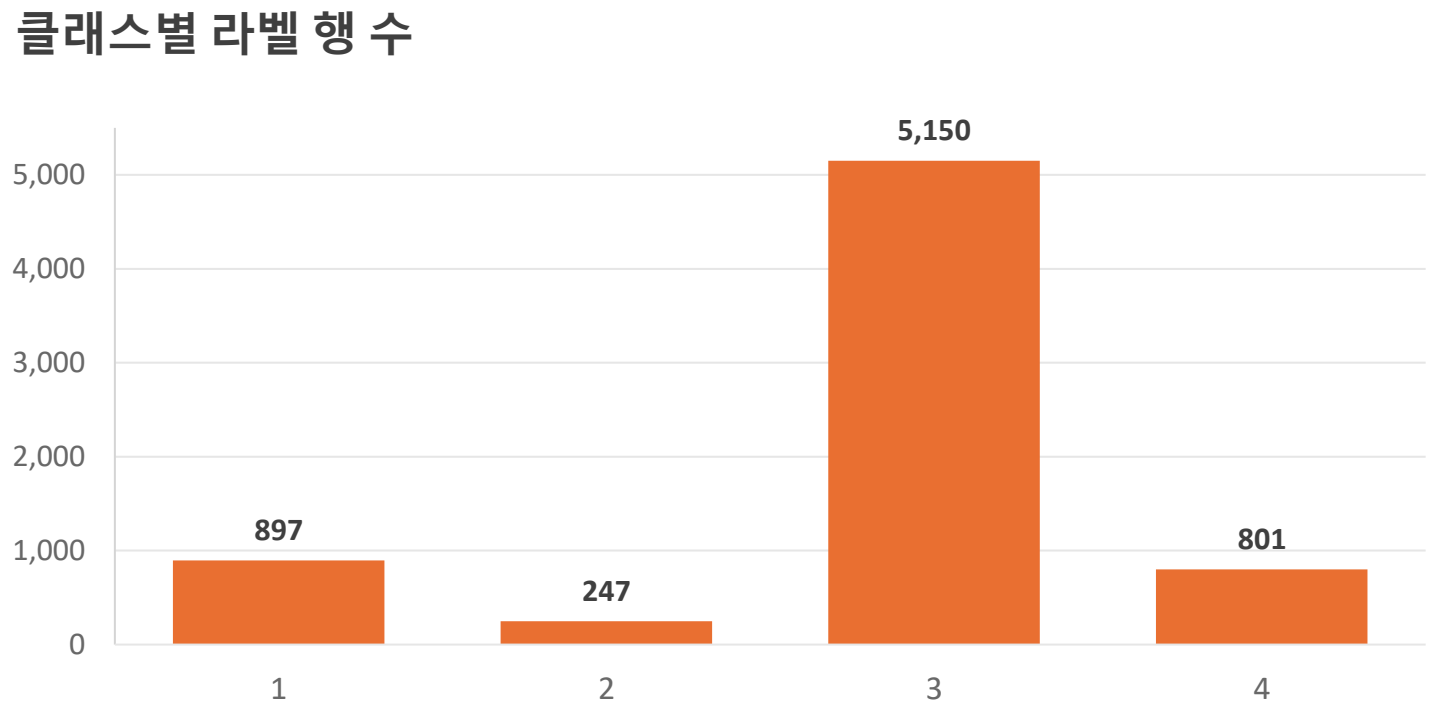
원본 1600×256 이미지와 RLE 결함 마스크

12,568

학습 이미지

6,666

결함 이미지

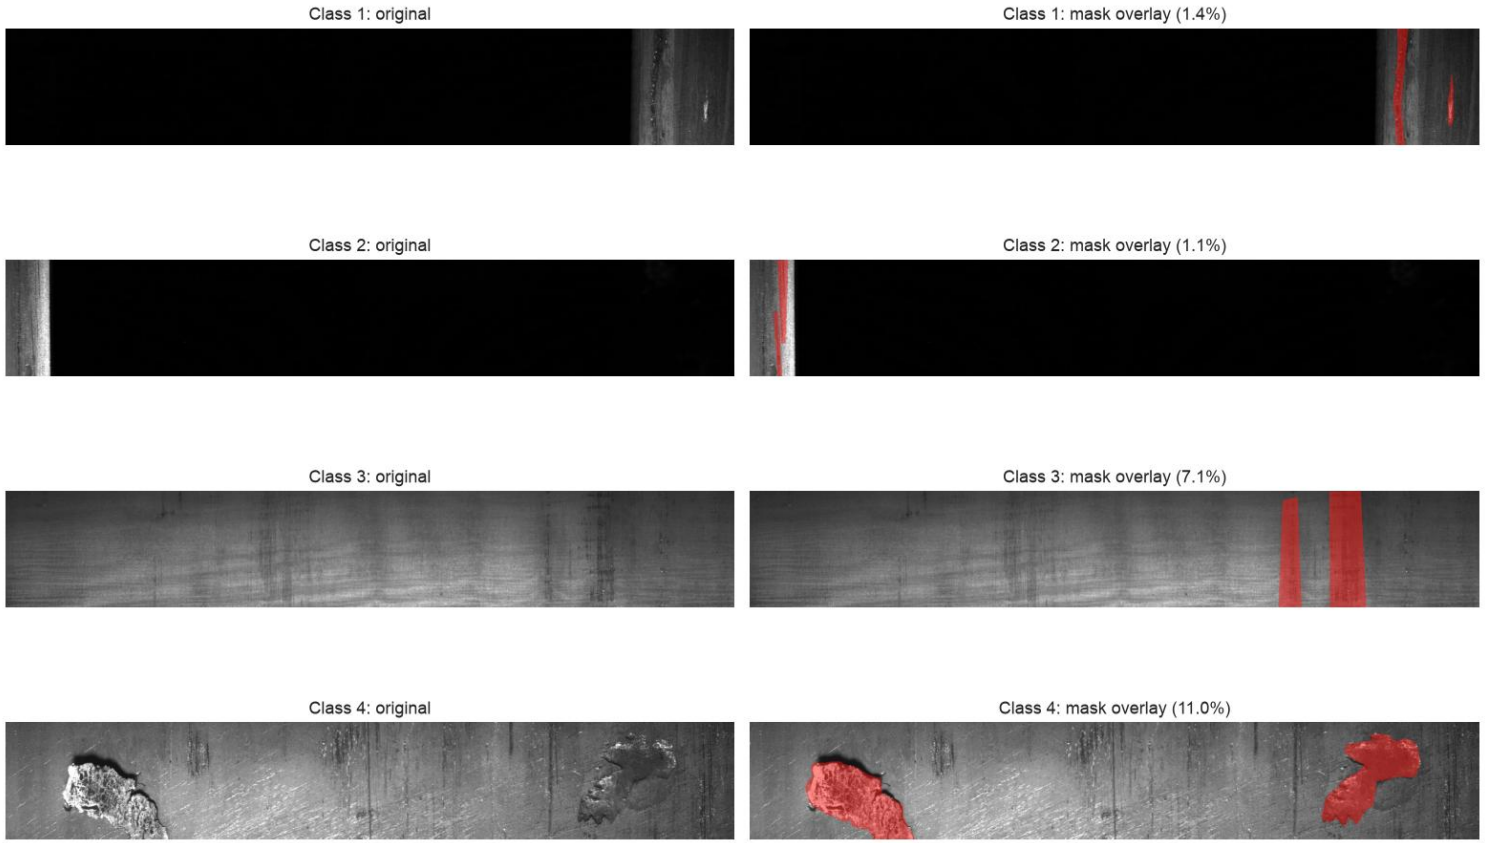


정상 이미지 5,902장 · 복수 클래스 결함 이미지 427장

클래스 3이 결함 라벨 7,095행 중 5,150행을 차지합니다.

결함 형태와 csv 정답

같은 이미지의 원본과 붉은 마스크



빨간 영역은 모델 예측이 아니라 train.csv의 정답 마스크입니다.

데이터 점검 12,568장 유지

중복과 누락을 확인한 뒤 원본 이미지 ID로 분할

주석 결측

0건

동일 이미지 파일 중복

0건

무효 결함 마스크 RLE

0건

복수 결함 이미지

427장

원본 학습 이미지 12,568장으로 분류 실험 · 정답이 없는 대회 test_images 5,506장은 성능 평가에서 제외

주석 결측과 동일 파일 중복은 확인되지 않았습니다. 복수 결함 427장은 그대로 유지했습니다.

평가용 데이터 분할

원본 이미지 ID를 기준으로 학습·검증·시험 구분

구분	전체 판별 실험	위치 분할 실험
학습	7,540장	360장
검증	2,514장	90장
홀드아웃 시험	2,514장	120장

전체 판별 실험은 12,568장, 위치 실험은 570장을 사용했습니다.

위치 모델의 결과를 전체 12,568장 성능으로 해석하면 안 됩니다.

같은 원본 이미지가 학습과 시험에 중복되지 않게 분할했습니다.

나영준 패치 기반 기준선

한 장을 12개 패치로 나누고 전처리·특징 추출 후 단계별 분류

원본 1600×256

256×256 패치 12개

OpenCV 전처리

CLAHE·Bilateral
Sharpen·Opening

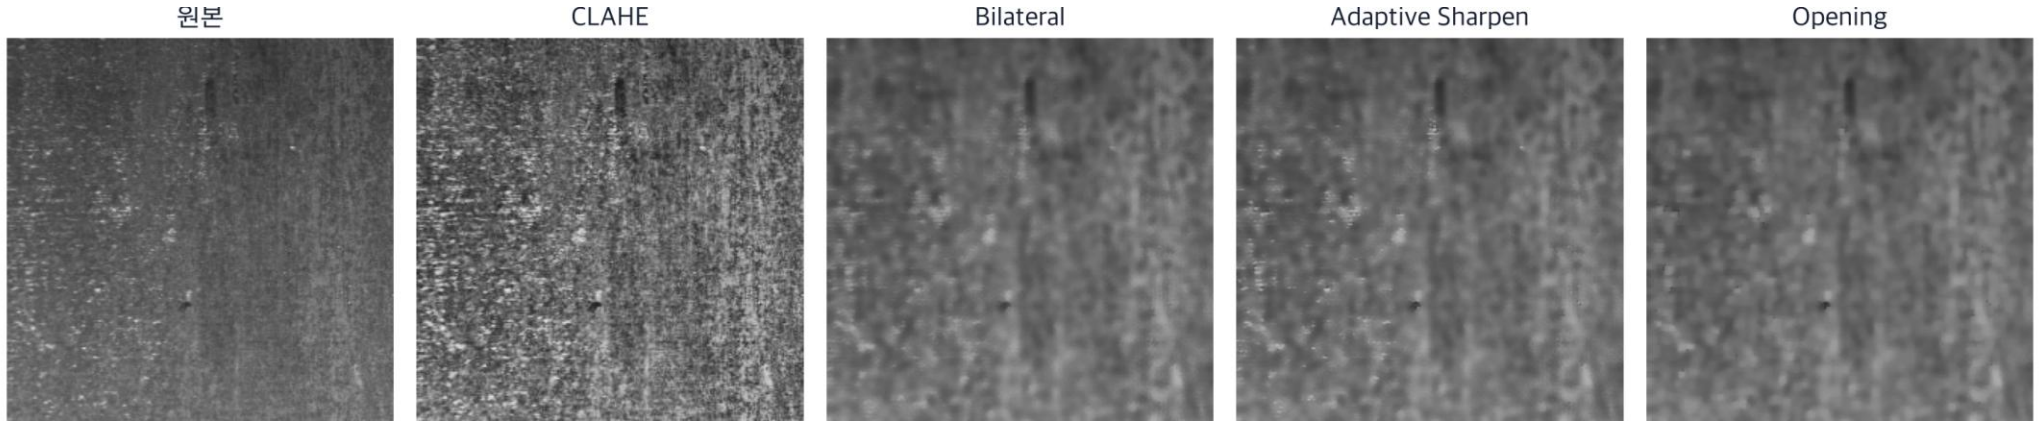
특징과 압축

1,944개 특징 → PCA 64차원

2단계 판별

LightGBM → XGBoost 유형

같은 결함 패치의 누적 전처리 변화



학습 90,480 · 검증 30,168 · 홀드아웃 30,168패치

12개 패치 중 하나라도 결함이면 사진 전체를 불량으로 판정했습니다.

나영준 기준선의 실제 성능

Stage1은 패치 결함 유무, Stage2는 결함 유형을 예측

검증에서 선택 **Stage1 LightGBM** **Stage2 XGBoost**

홀드아웃 평가 단위	재현율	정밀도	F1	정상 경보 FP
Stage1 패치	68.29%	50.20%	57.86%	4,284패치
Stage1 이미지 집계	94.15%	63.54%	75.88%	720장

Stage2 유형 분류 macro F1



유형 분류만의 점수보다 두 단계를 연결한 결과가 낮아지는 점을 확인했습니다.

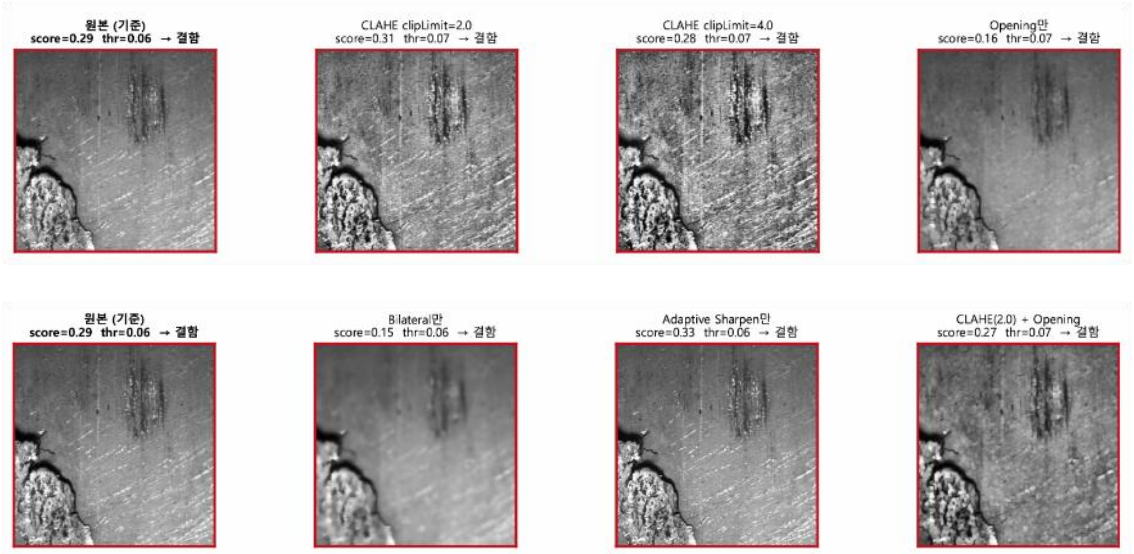
채영지 기준선 필터의 단독·조합 실험

LightGBM을 유지하고 필터 강도와 적용 조합을 바꿔 비교

같은 실험의 정밀도 비교

원본 입력	32.40%
CLAHE 2.0 / 4.0	31.36 / 30.06%
Bilateral 단독	32.40%
Adaptive Sharpen 단독	32.66%
Opening 단독	**33.35%**
CLAHE 2.0 + Opening	31.07%

같은 사진의 필터별 변화



원본보다 +0.95%p

정밀도 비교는 채영지 자료 내부 실험입니다. 최종 RF와 평가 조건의 일치는 확인되지 않았습니다.

Opening 단독의 정밀도는 33.35%로 원본 입력보다 0.95%p 높았습니다.

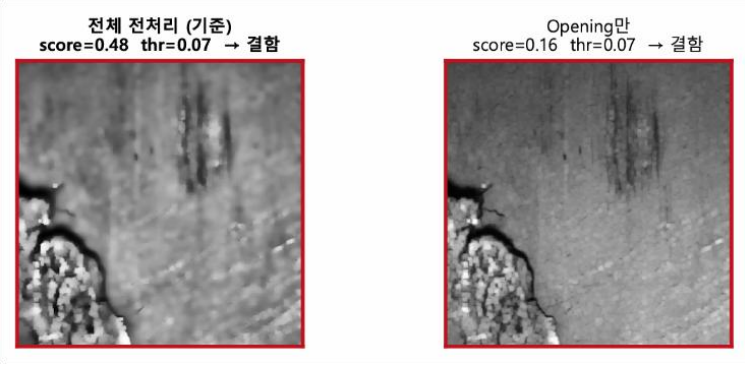
채영지 Opening 단독의 성능 비교

전체 전처리와 Opening 단독을 같은 LightGBM 실험에서 비교

Opening 단독

정밀도 +2.39%p · F1 +2.40%p

재현율 −1.91%p



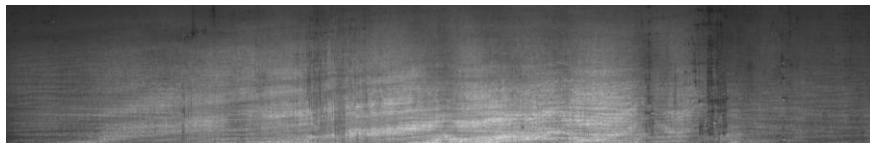
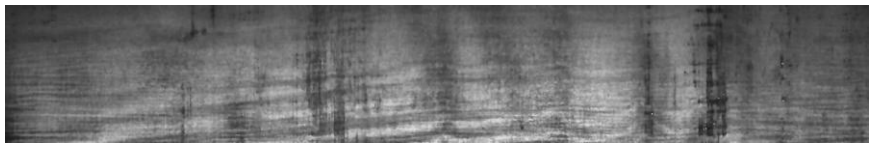
조건	재현율	정밀도	F1
전체 전처리	94.96%	30.96%	46.70%
Opening 단독	93.05%	33.35%	49.10%
차이	−1.91%p	+2.39%p	+2.40%p

전처리 조합만 바꿔서는 결함 누락과 오경보를 동시에 개선하지 못했습니다.

정밀도와 F1은 높아졌지만 재현율은 1.91%p 낮아졌습니다.

김현모 누적 OpenCV 전처리의 변화

같은 결함 사진에 CLAHE, Bilateral, Sharpen, Opening을 순서대로 적용한 시연

	원본	누적 전처리 적용
Class 1		
Class 2		
Class 3		
Class 4		

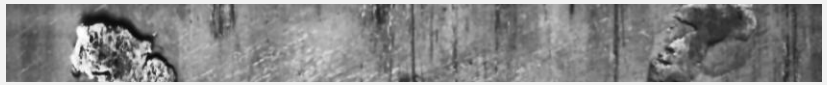
제공받은 PPT의 시연 이미지입니다. 아래 성능 수치는 별도 Extra Trees 검증 패치 실험입니다.

사진의 대비는 바뀌었지만, 다음 페이지의 패치 F1은 CLAHE 기준보다 낮았습니다.

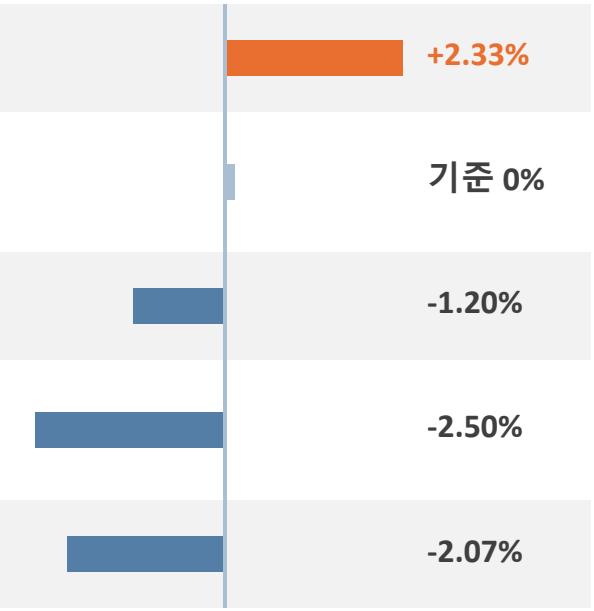
김현모 누적 전처리 후 패치 F1 하락

Extra Trees 검증 패치 216개에서 CLAHE 기준 누적 필터 비교

같은 사진의 누적 처리 시연

01	원본	
02	CLAHE	
03	+ Bilateral	
04	+ Sharpen	
05	+ Opening	

CLAHE 기준 F1 변화



원본 → 최종 F1 62.33% → 59.65% (−2.68%p)

김현모 자료의 216패치 실험 수치 · 왼쪽 사진은 같은 강판으로 재현한 시연

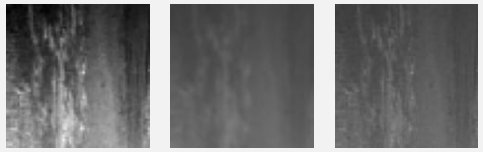
Bilateral, Sharpen, Opening을 더한 뒤 F1은 CLAHE 기준보다 낮았습니다. 최종 모델에서는 필터를 다시 평가했습니다.

김윤태 34가지 입력 조건을 검토

같은 결함 패치에서 단일 입력 27개(원본 포함)와 조합 7개를 비교

11

밝기·노이즈



MinMax　Gaussian　Unsharp

정규화 · CLAHE · 감마
평활화 · 샤프닝

09

이진화·경계



Threshold　Laplacian　Canny

임계값 · Otsu
Sobel · Laplacian

07

형태학



Opening　Gradient　Tophat

침식 · 팽창 · 열림·닫힘
경계 · Tophat · Blackhat

07

전처리 조합



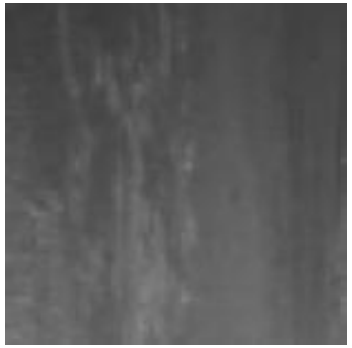
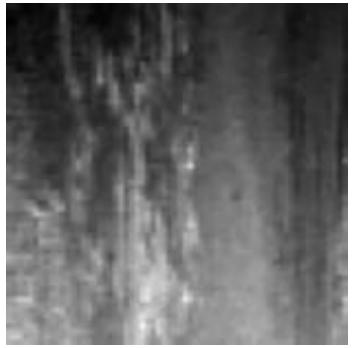
Bilateral　Unsharp　Opening

CLAHE와 평활화·샤프닝
열림을 결합

밝기·경계·형태학·조합을 폭넓게 시험했습니다. 다음 장에서 대표 변화를 확대해 보여줍니다.

김윤태 대표 전처리의 이미지 변화

같은 결함 패치에서 밝기·경계·형태학·조합 결과를 확대 비교

기준	밝기	경계	형태학	조합
				
원본	**MinMax**	**Laplacian**	**MorphGradient**	**CLAHE+Unsharp**
검증 AP 0.629	검증 AP 0.649	검증 AP 0.685	**검증 AP 0.703**	검증 AP 0.632

최고 단일 변환 0.703

최고 조합 0.632

검증 AP는 형태학 경계가 가장 높았습니다. 밝기·경계·조합 변화만 대표 이미지로 보여줍니다.

김윤태 패치 AP 상승, 최종 입력은 보류

시험 패치 1,200개 · 결함 유형과 사진 단위 경보까지 함께 확인

시험 AP 결함 패치 탐지



+0.050

4종 유형 분류 macro F1



−0.050

정상 사진 20장 모두 경보 · 고재현율 패치 경보 설정

AP 차이 95% 구간 −0.001 ~ +0.105 (0 포함) · 최종 RF와는 평가 단위가 다름

MorphGradient는 패치 탐지 AP를 높였지만 유형 분류는 낮아졌고, 정상 사진 경보 문제도 남았습니다.

패치 분류 → 사진 한 장씩 판별

200×32 회색조 특징과 RandomForest

밝기·명암, 가로·세로 변화량, 다섯 구간의 통계를 입력으로 사용

95.6%

홀드아웃 재현율

결함 누락 59장

82.4%

홀드아웃 정밀도

정상 경보 272장

6.66 ms

한 장 처리 시간

OpenCV 200×32 기준

패치 탐색에서 AP 개선 후보는 있었지만 이미지 오경보 문제는 남아, 사진 한 장씩 판별하는 방식을 시험했습니다.

축소 크기 후보

속도만 보면 100×16, 누락까지 보면 200×32

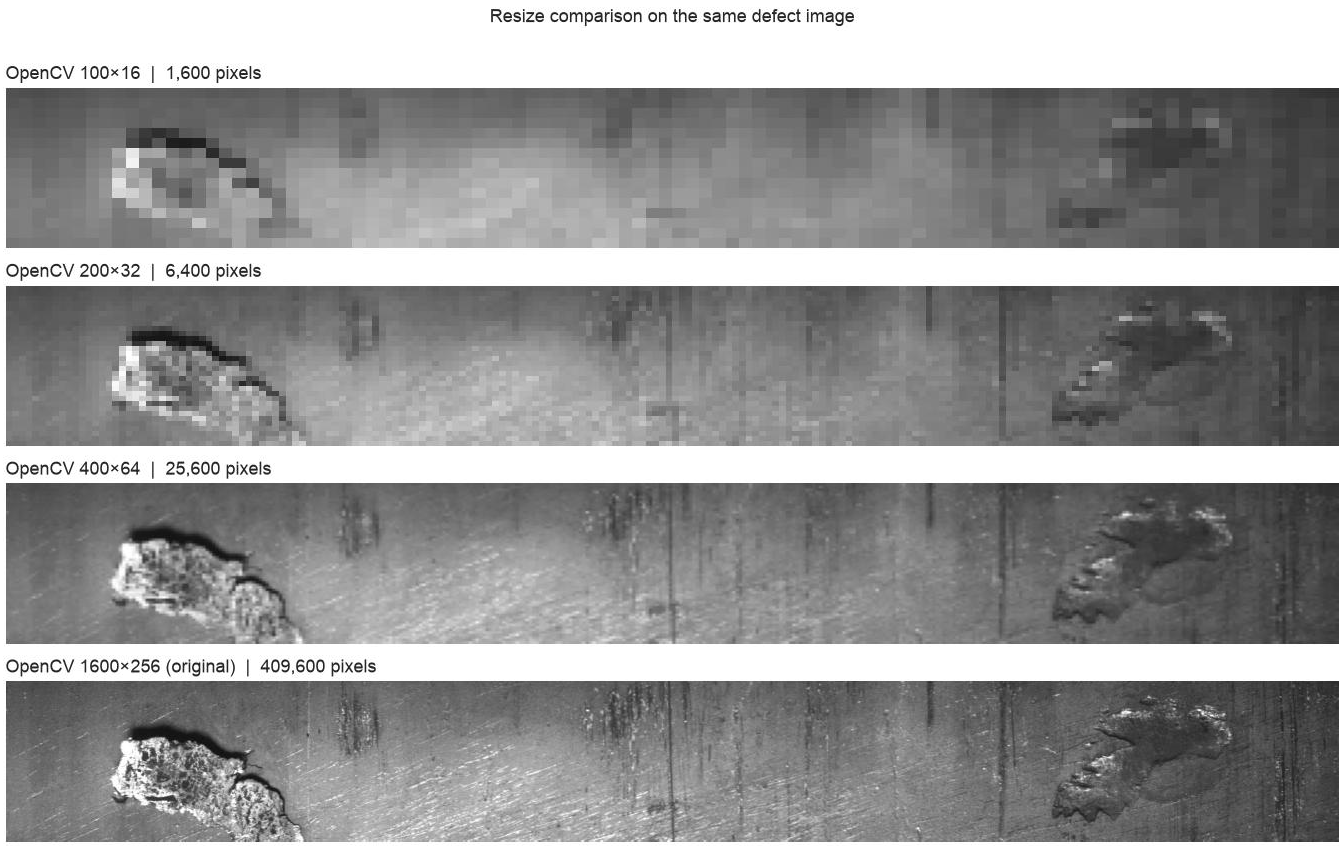
입력 크기	시간/장	시험 재현율	누락 FN	판단
100×16	6.64 ms	94.6%	72장	누락 증가
200×32	6.66 ms	95.6%	59장	선택
400×64	7.55 ms	93.9%	81장	재현율 저하
1600×256	21.10 ms	95.5%	60장	처리 지연

크기가 커진다고 이 특징 기반 모델의 재현율이 늘지는 않았습니다.

200×32는 원본보다 약 3.2배 빠르고 결함 누락은 59장으로 비슷합니다.

축소 이미지와 성능 변화

같은 클래스 4 결함을 네 크기로 비교하고 원본 대비 수치를 확인



원본 대비 200×32

한 장 처리 시간

원본	21.10 ms
200×32	6.66 ms

약 68% 단축

결함 재현율

원본	95.5%
200×32	95.6%

200×32 기본

정밀도	누락 FN	정상 경보 FP
82.4%	59장	272장

200×32는 처리 시간을 약 68% 줄이면서 결함 재현율은 거의 같았습니다.

초기 기준선 대비 개선안의 성능

크기와 전처리 후보를 검토한 뒤 이미지 경보 결과를 비교

원본 이미지 단위	초기 기준선 패치 경보	개선안 한 장씩 판별	관찰된 차이
재현율	94.15%	95.57%	+1.42%p
정밀도	63.54%	82.41%	+18.86%p
F1	75.88%	88.50%	+12.63%p
정상 오경보 FP	720장	272장	448장 감소
결함 누락 FN	78장	59장	19장 감소

초기 기준선: 12개 패치 중 하나라도 양성이면 경보 · 개선안: 사진 한 장을 200×32로 축소해 판별

홀드아웃 이미지 ID 일치 여부는 미확인: 수치 차이는 파이프라인별 관찰값입니다.

사진 한 장씩 판별한 개선안의 정밀도와 F1이 높고 정상 오경보가 적었습니다.

분류 알고리즘 성능 비교

같은 Pillow 200×32 입력·39개 특징, 동일한 평가 이미지 2,514장

분류 모델	재현율	정밀도	F1	누락 FN	오경보 FP
RandomForest	**95.57%**	**82.41%**	**88.50%**	**59장**	**272장**
HistGradientBoosting	95.12%	82.88%	88.58%	65장	262장
ExtraTrees	94.82%	82.99%	88.52%	69장	259장
LightGBM	95.57%	81.93%	88.23%	59장	281장
XGBoost	95.50%	80.93%	87.61%	60장	300장
KNN	94.07%	80.59%	86.81%	79장	302장
RBF SVM	94.60%	75.78%	84.15%	72장	403장
LogisticRegression	94.52%	63.99%	76.32%	73장	709장
Linear SVM	94.52%	63.86%	76.23%	73장	713장

검증 기준 선택: HistGradientBoosting　최종 사용: RandomForest

RF는 결함을 6장 덜 놓쳤고, HistGradientBoosting은 정상 오경보가 10장 적었습니다.

최종 모델로 채택한 조합

OpenCV 200×32와 RandomForest

6.66 ms

평균 한 장 지연

59장

놓친 결함

272장

정상 경보

최종 모델 내부 비교

Pillow 200×32도 같은 재현율 95.6%와 누락 59장을 기록했습니다.
두 구현의 작은 속도 차이는 실행 상태에 따라 달라질 수 있습니다.

200×32는 속도와 누락의 균형이 좋았지만 위치 표시 기능은 없습니다.

결함 위치 모델 비교와 U-Net 선택

같은 570장 표본에서 검증 재현율을 먼저 비교

1600×256 원본 → 400×256 패치 4개 → 320×192 모델 입력

모델	검증 재현율 / Dice	시험 재현율 / Dice	중앙 지연
U-Net 선택	100.0% / 0.497	96.9% / 0.478	36.5 ms
YOLO semantic	91.7% / 0.476	93.8% / 0.446	44.1 ms

선정 근거

검증 재현율 95% 기준을 넘은 U-Net 채택

결함 64장 중 62장 검출 · 누락 2장

함께 확인한 한계

정상 56장 중 52장에 위치 경보

U-Net 마스크에서 최종 박스 표시까지

OpenCV 후처리로 결함 위치를 설명하는 상위 2개 박스 생성

점수 지도 → 임계값·연결 영역 → 누적 점수 순위 → 상위 2개 박스

박스 표시 개선

① 누적 점수로 후보 선택

검증 박스 Dice 0.466 → 0.476

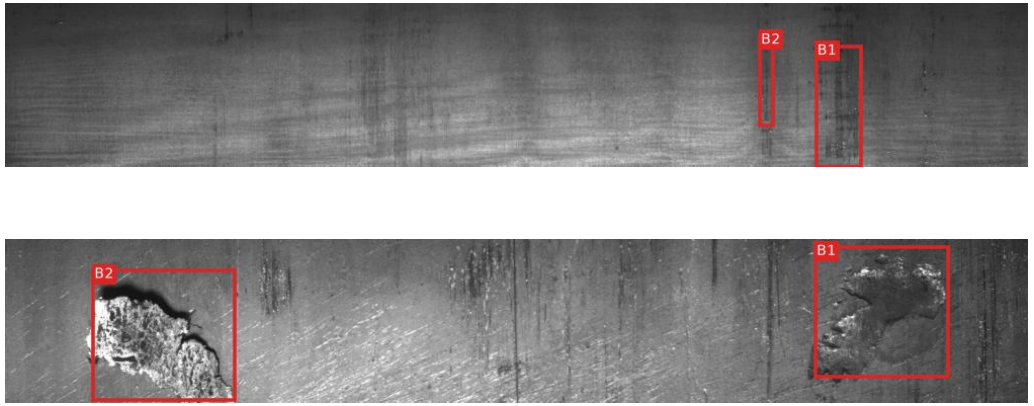
② 작은 후보에서만 임계값 완화

클래스 3 포함률 51.5% → 56.1%

시험 박스 Dice 0.450 → 0.470

조건: 원래 후보 최대 면적 2,000 px 미만

최종 박스 예시

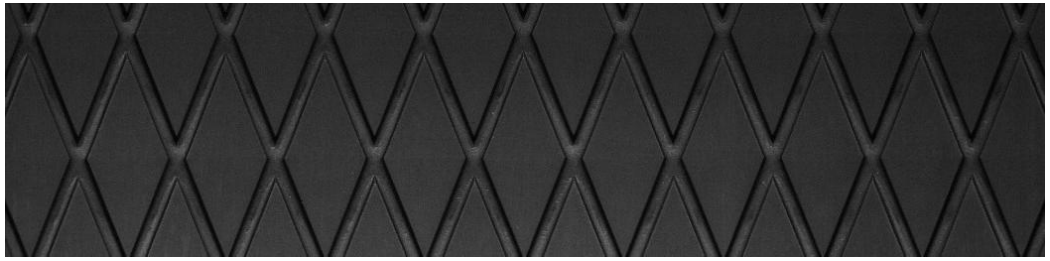


빨간 사각형: 상위 2개 예측 박스

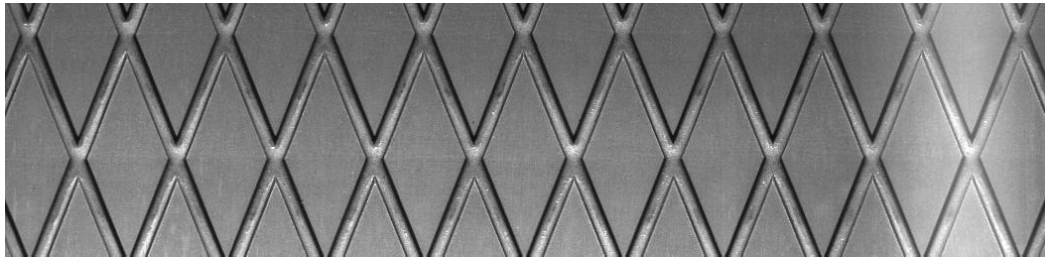
합성 조명 이미지와 결함 재현율

같은 합성 조명 사진에서 결함 재현율

합성 사진 예시

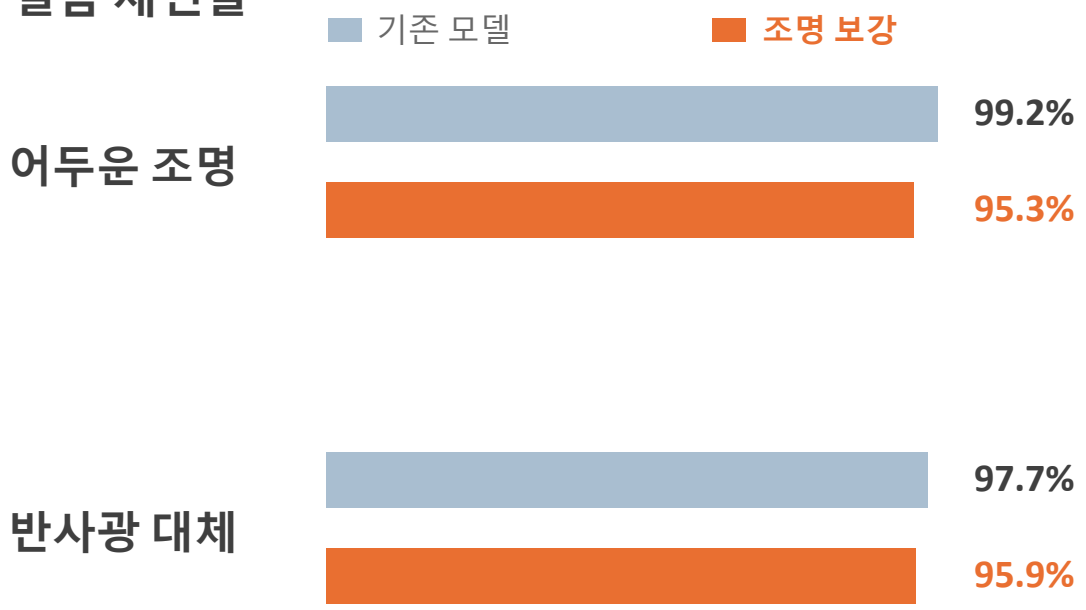


어두운 조명 · 합성 예시



반사광 대체 · 합성 예시

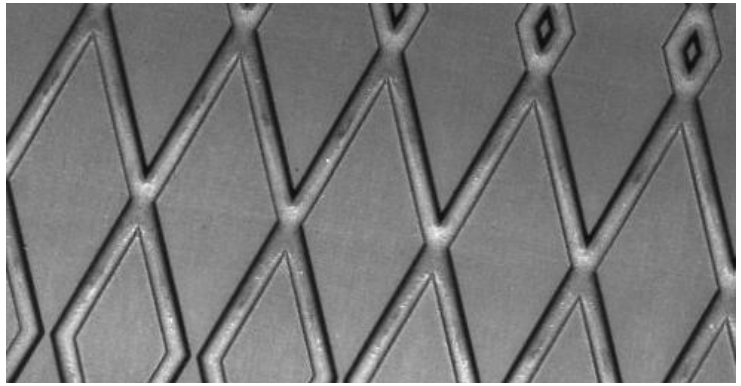
결함 재현율



환경 변수를 고려한 추가 실험으로 성능을 검증했습니다.

합성 공정 오류별 예시와 검출 결과

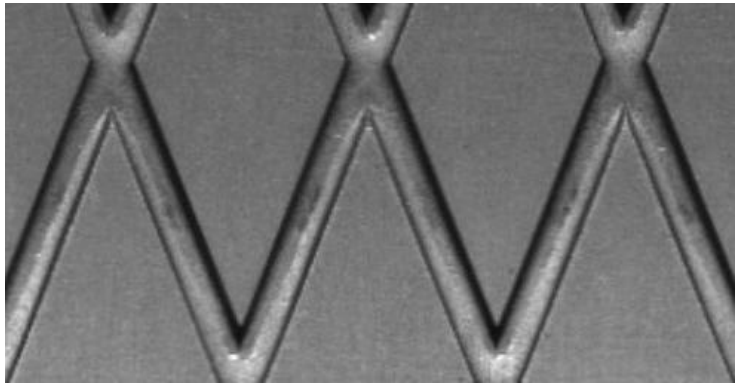
별도 CNN으로 유형별 합성 이미지 200장씩 시험



기울어짐

95% 190 / 200장

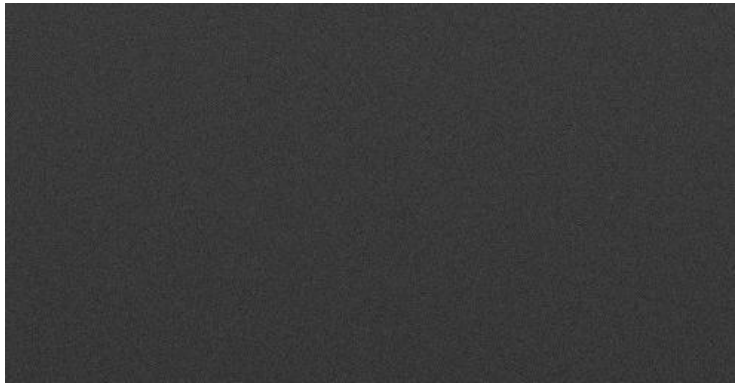
회전과 위치 변화



확대

93% 186 / 200장

중앙 잘라내기와 재확대



빈 트레이 대체

100% 200 / 200장

강판 무늬가 없는 합성 장면

사진은 원본을 변형한 합성 예시입니다. 실제 설비 사진에서 다시 검증해야 합니다.

정상 투입 사진 1,200장 중 14장(1.2%)을 공정 오류로 잘못 분류했습니다.

현재 결과의 한계와 다음 검증

공개 데이터와 합성 변형을 실제 설비 사진으로 다시 시험

확인된 한계	개선방안
데이터 확보 및 일반화 검증의 어려움	실제 철강산업 데이터 확보와 산업현장 투입 검증
전처리가 항상 성능 향상으로 이어지지 않음	추가 반복 검증으로 성능 향상 조건 도출
이미지 축소 과정에서 특징 유실 가능성	분석 과정에서 유실 여부를 검증한 뒤 개선
실제 운영 부담과 경제적 효과를 알 수 없음	실제 산업현장의 손익분기점 확인

초기 기준선과 최종 RF의 시험 이미지 ID 일치 여부도 확인한 뒤 성능 차이를 다시 계산해야 합니다.

실제 공장 도입 여부는 현장 사진에서 누락, 정상 경보, 검사 시간을 함께 측정한 뒤 판단해야 합니다.

핵심 성과 요약

공개 데이터 실험과 문헌을 구분해 읽는 결과

딥러닝 개선 · 결함 재현율

95.57% → 99.70%

RF 입력 축소 · 한 장 처리 시간

21.10ms → 6.66ms

육안 검수와 RF · 1,000장 참고 계산

문헌 100분 / RF 6.7초

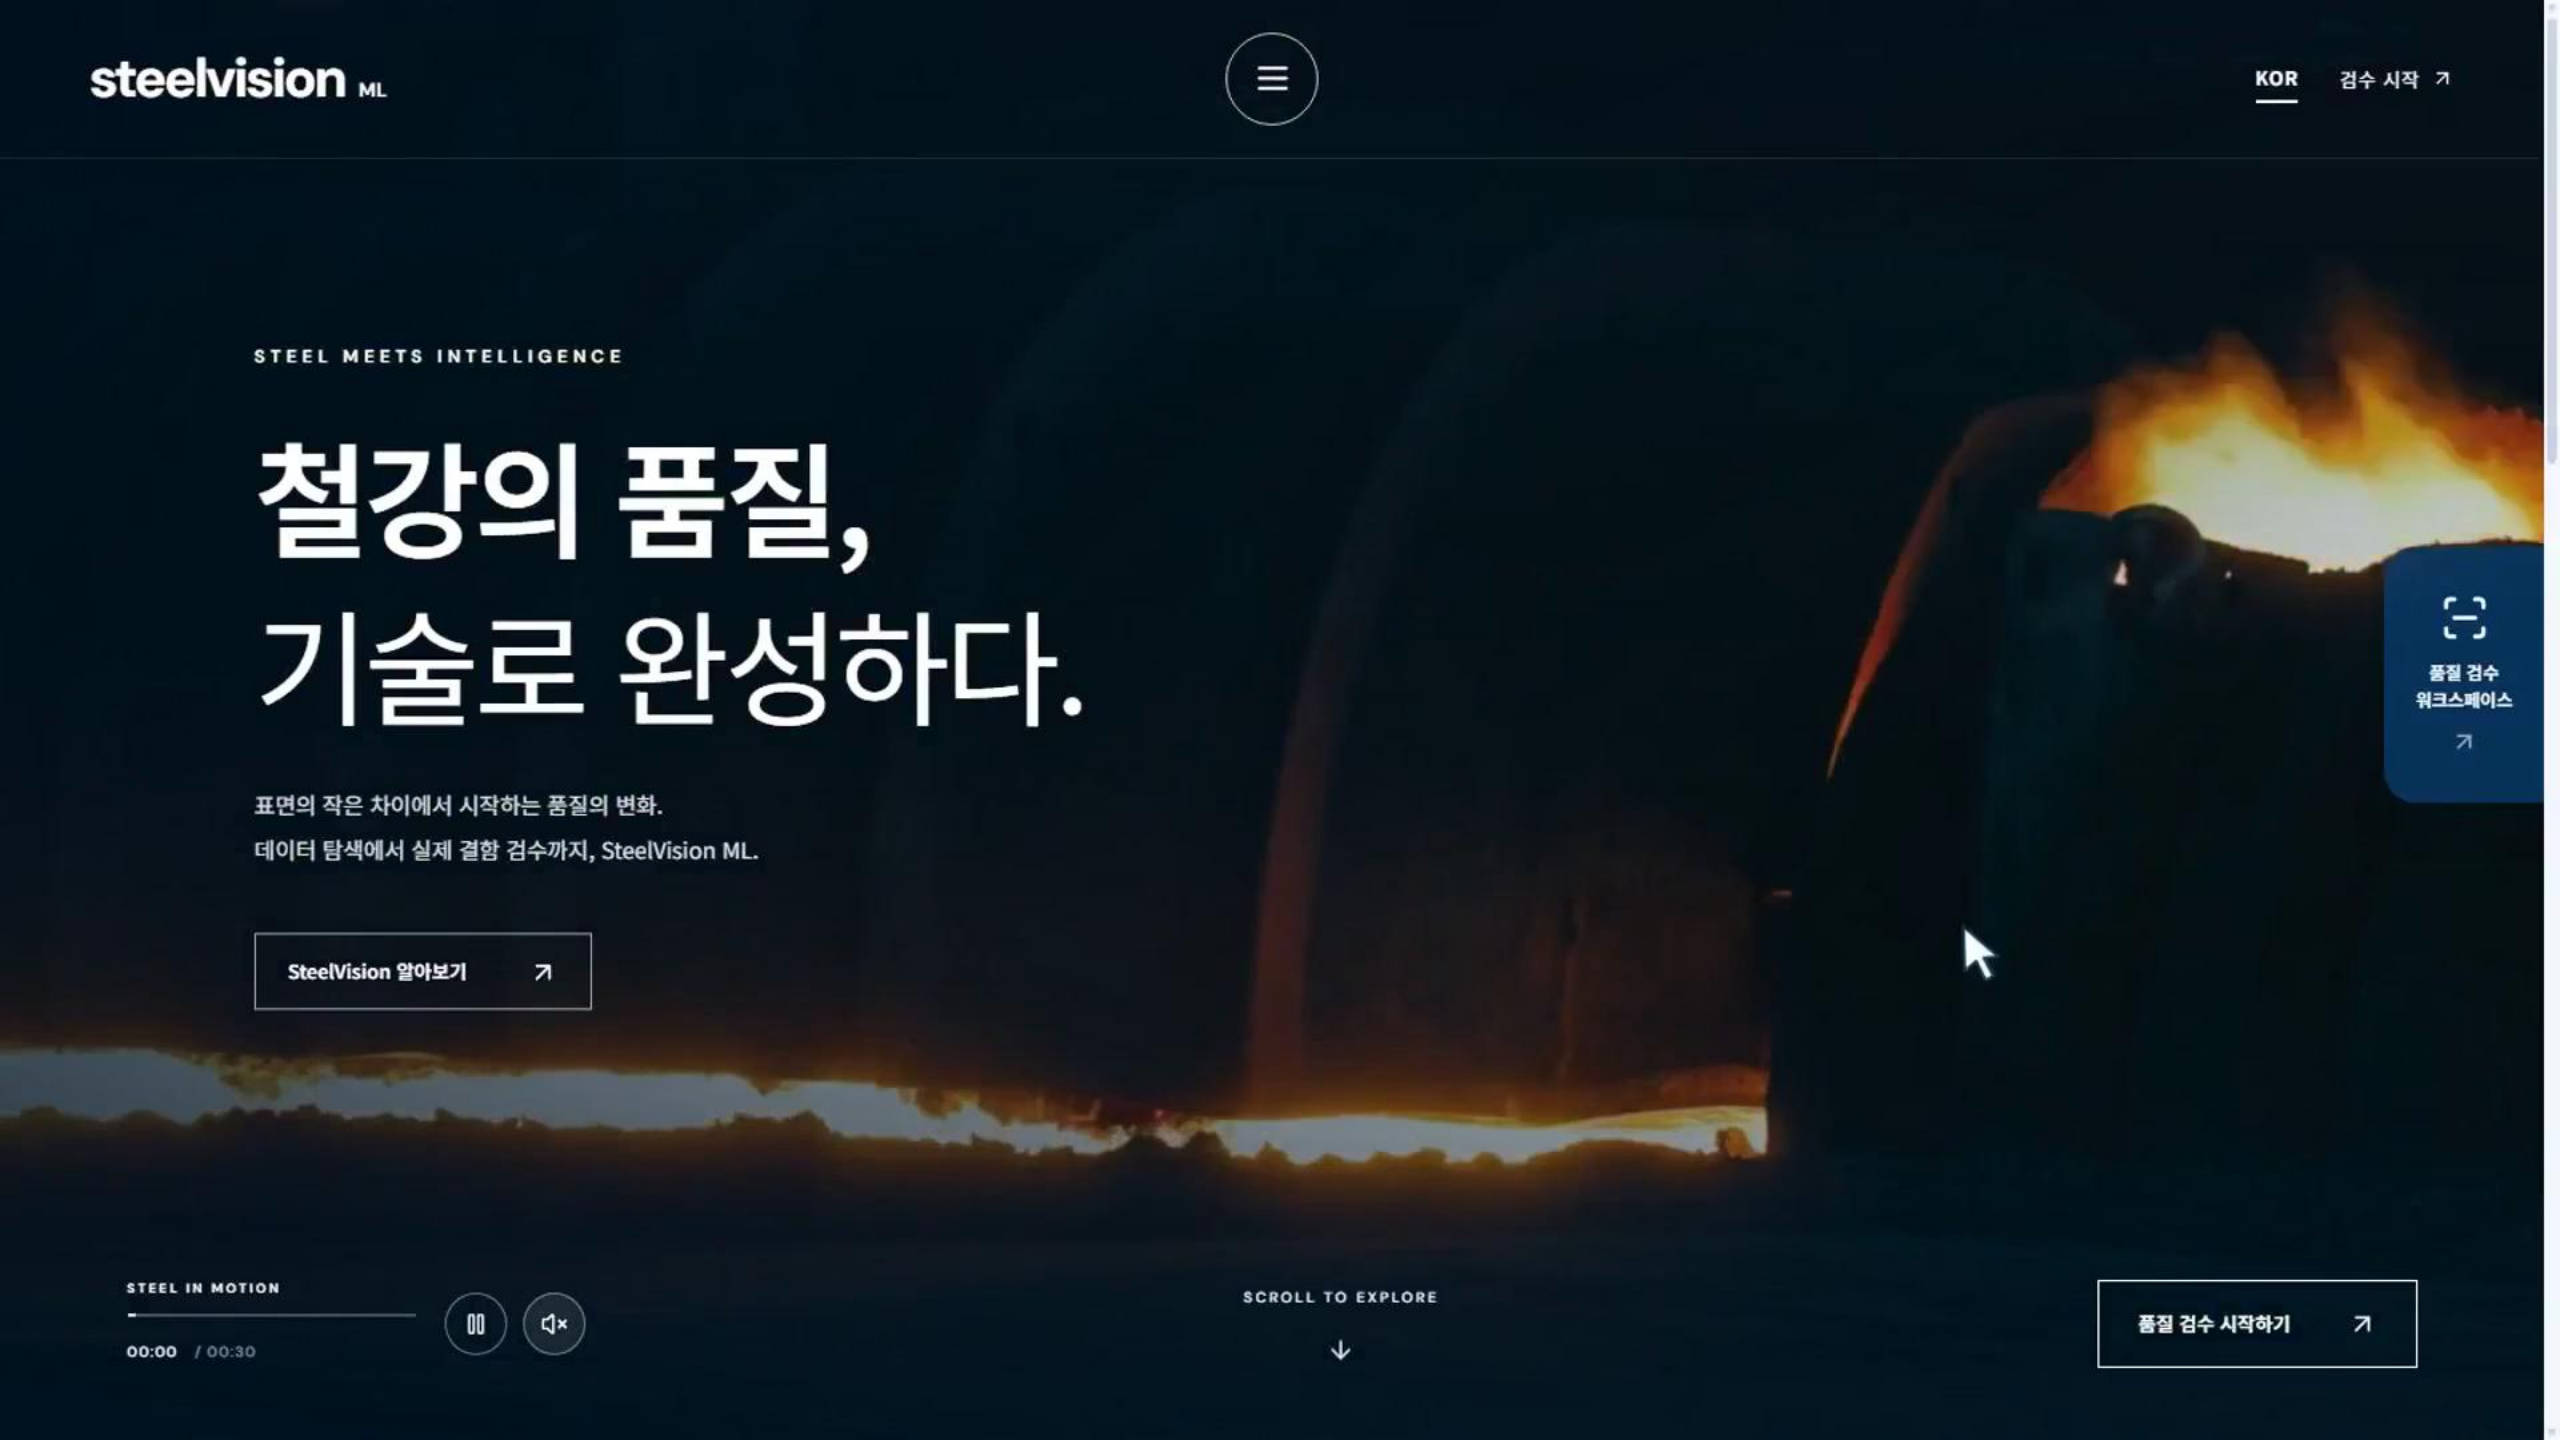
초기 기준선과 개선안의 경보

결함 누락 78 → 59장

정상 오경보 720 → 272장

육안과 RF는 서로 다른 조건의 수치입니다. 초기·최종 모델 시험 이미지 ID의 일치 여부도 미확인입니다.

RF 축소 입력은 처리 시간을 줄였습니다. 딥러닝의 높은 재현율도 실제 공장 사진에서 재검증해야 합니다.


steelvision ML
KOR
검수 시작
STEEL MEETS INTELLIGENCE
철강의 품질,
기술로 완성하다.
표면의 작은 차이에서 시작하는 품질의 변화.
데이터 탐색에서 실제 결함 검수까지, SteelVision ML.
SteelVision 알아보기
품질 검수
워크스페이스
STEEL IN MOTION
00:00 / 00:30
SCROLL TO EXPLORE
품질 검수 시작하기